



**北京航空航天大学**  
B E I H A N G U N I V E R S I T Y

## 第三十二届“冯如杯”竞赛主赛道项目论文

2022 年 4 月

# 基于深度学习的短临降水预测平台

# 目录

目录.....	I
摘要.....	II
Abstract.....	III
一、 引言.....	1
二、 产品与技术.....	2
（一） 产品功能.....	2
（二） 产品技术.....	3
（三） 产品展示.....	10
三、 商业模式.....	13
（一） 市场分析.....	13
（二） 产品定位.....	13
（三） 推广计划.....	14
（四） 产品策略.....	14
总结.....	15
参考文献.....	16

## 摘要

短临降水预测是指利用雷达回波、自动站、卫星等气象观测数据，对未来 0-2 小时内的降水量进行预测，对人们的生产生活意义重大。短临降水预测通常采用数值模式和传统雷达外推方法，前者依赖对复杂物理偏微分方程的求解，计算量大，预测速度慢，后者基于光流外推，难以充分挖掘历史观测数据的时空特征，预测精度有限。近些年，随着人工智能技术的发展，深度学习方法被广泛应用在时空序列预测任务上，性能表现突出。因此，本文研究基于深度学习的短临降水预测技术，根据雷达图像及温压湿风等物理参数，研究降水预测算法，构建短临降水预测平台。具体地，针对相控阵天气雷达采集的雷达回波图像，分别构建基于 U-Net 和 PredRNN 的降水预测模型，探索不同优化方案，并对模型进行集成；针对地面自动气象站点采集的温压湿风等多源多模态数据，结合大气物理知识，研究基于物理约束的特征向量融合，以供后续作为雷达回波图像的辅助输入，进一步提升预测精度。

关键词：短临降水预测，U-Net，PredRNN，模型集成，多源多模态

## Abstract

Short-term precipitation prediction refers to the use of radar echoes, automatic stations, satellites and other meteorological observation data to predict the precipitation in the next 0-2 hours, which is of great significance to people's production and life. Short-term precipitation prediction usually adopts numerical mode and traditional radar extrapolation method, the former relies on the solution of complex physical partial differential equations, the calculation amount is large, the prediction speed is slow, the latter is based on optical flow extrapolation, it is difficult to fully excavate the spatio-temporal characteristics of historical observation data, and the prediction accuracy is limited. In recent years, with the development of artificial intelligence technology, deep learning methods have been widely used in spatiotemporal sequence prediction tasks, and the performance is outstanding. Therefore, this paper studies the short-term precipitation prediction technology based on deep learning, studies the precipitation prediction algorithm based on the radar image and the physical parameters such as temperature and pressure humidity, and constructs a short-term precipitation prediction platform. Specifically, for the radar echo images collected by phased array weather radar, the precipitation prediction models based on U-Net and PredRNN are constructed, different optimization schemes are explored, and the models are integrated; for the multi-source multimodal data such as temperature, pressure, humid wind and other multi-source multimodal data collected by ground automatic meteorological stations, combined with atmospheric physics knowledge, the eigenvector fusion based on physical constraints is studied for subsequent use as auxiliary inputs for radar echo images to further improve the prediction accuracy.

Keywords: Short-term, precipitation, model integration, U-Net, PredRNN, bidirectional LSTM, Multi-source, Multi-modal

# 一、引言

## （一）项目背景

短临降水预测是指利用雷达回波、自动站、卫星等气象观测数据对短时临近（即未来 0-2 小时）的降水进行分钟级、公里或街道级的预测，其研究对象是中小尺度系统，对预测的精度和时效性要求较高。短临天气对物流运营、港口作业等工作影响较大，短临预报可以帮助政府和企业做出正确决策。随着人工智能的发展，对短临降水预测的算法研究已经取得了一定进展，不过在预测算法和精度上仍存在很多问题，从学术角度看，短临降水预测领域还存在巨大研究空间<sup>[3]</sup>。

## （二）科研意义

市场上大多数降水预测产品采用传统的数值预报模式，需要借助经典的分析或计算工具，在一定程度上不可避免地引入了不确定性，且由于微分方程求解较为复杂，即使借助先进的计算工具，也需要消耗大量的计算资源和时间成本。目前，深度学习模型在降水预测任务上的应用还在较为初级的阶段，模型依赖于大数据输入，难以处理多源多模态数据，预测精度和时效性低下，难以应用落地。因此，本项目构建降水预测模型，研究面向应用的集成方案，并对多源多模态数据融合进行初步探索，有助于真实、开放环境下的时空序列预测研究。

## （三）项目工作

本项目研究基于深度学习的短临降水预测技术，根据雷达图像及温压湿风等物理参数，研究降水预测算法，构建短临降水预测平台，主要完成工作如下：

1. 针对相控阵天气雷达采集的雷达回波图像（即雷达反射率数据），构建基于 U-Net 的时序预测模型。采用基于注意力机制的 SmaAt-UNet 模型，以 60 分钟的雷达回波图像作为输入，生成未来 0-2 小时内、每隔五分钟一帧的降水预测。

2. 针对雷达回波图像，构建基于 LSTM 的时序预测模型。采用 PredRNN 模型为基准模型，探索不同优化方案。一方面，将 LSTM 变体的 PredRNN 的结构由单向改为双向。反向的 LSTM 通过对输入序列的逆向学习，可以保留部分未来的降水分布信息，与正向 LSTM 的输出融合，引导模型学习云层移动的一些潜在规律。另一方面，对生成的

预测结果引入感知损失，在像素级误差的基础上增加感知误差，引导模型衡量预测结果在高层语义之间的相似性。

3. 在 1、2 的基础上，将 PredRNN 和 U-Net 模型进行集成，提出了 predRNN-SmaAtUNet 集成深度学习预测模型。模型集成可以有效地结合不同模型的特点，从而提高整体的预测精度。在构建短临降水预测平台时，考虑到 PredRNN 模型的时序预测能力较强，而常用于图像分割的 U-Net 模型预测空间能力较强，且较为轻量，使用 stacking 方式对 1、2 两个模型进行集成。

4. 针对地面自动气象站点采集的温压湿风等多源多模态数据，研究温度、比湿、位势高度、风速等多模态数据的初步融合。不同来源的数据可以为深度学习算法提取潜在的新关系提供基础，不同模态的数据可以互相补充，弥补其预测中的不足。1. 结合大气物理知识对多源数据进行处理。利用成熟的大气物理知识对一个或多个特征加以处理或施加约束，可以使转化后的特征与降水相关性更强，减轻过拟合程度。

## 二、产品与技术

### （一）产品功能

我们的产品是一个基于深度学习的降水短临预测平台。当用户使用我们的平台，选择需要了解的地区后，平台通过调用气象数据的 API，获取指定区域一定时长的雷达回波数据及卫星等数据，并可视化在平台上。此外，利用训练好的模型，平台还可以实时预测指定区域 0-2 小时的降水量，并将结果通过动图形式可视化在平台上，进行分钟级的更新，使用户可以通过我们的平台实时掌握短临天气情况，平台的实时性与准确有利于用户对短期行程更好的规划以及对突发极端天气更好的防御。

除了上述基本的短临降雨预测功能以外，平台还提供了以下衍生功能：

（1）用户能够访问历史降水数据以及平台利用历史数据预测出的降水数据，将历史预测结果和真实值进行可视化对比，从而提高平台的透明度，让用户能够了解到平台的预报精度，从而增加用户对平台的信任度。

（2）平台除了能够利用我们的主算法模型进行短临预报，也能够根据输入数据及模型继承方式的不同，提供不同的算法方案，并显示不同的可视化结果和评价指标，从而突出我们主算法的有效性、准确性、实时性。

(3) 平台除了短临降雨预报的功能, 为了能够更加贴合并满足用户对于短临天气的需求, 我们还推出了对极端恶劣天气推演的功能, 展示在极端恶劣天气下, 对强对流天气的预报效果。

## (二) 产品技术

### 1. 基于 U-Net 和 PredRNN 的降水预测模型

一直以来, 专家们通过数值天气预报(NWP)的方式预测降水, 但是这种方法很难利用过去的时刻信息, 虽然基于 NWP 的模型可以生成几小时到几天的准确天气预报, 但是它们涉及解决高度复杂的计算量很大的模型时需要巨大算力, 因此通常在昂贵的超级计算机上执行。而且由于它们对计算时间的要求很高, NWP 模型不太适合从几分钟到 6 小时内的短期预报, 短期预报模型能够使用最新的可用天气观测数据来创建预测, 与 NWP 模型相比, 更具有时效性。因此, 针对相控阵天气雷达采集的雷达回波图像, 分别构建基于 U-Net 和 PredRNN 的时序预测模型, 具体如下:

#### 1.1 SmaAtUNet 降水预测

传统的 UNet 本质上是 CNN 的一种, 它没有用于记忆的单元, SmaAt-UNet 在 UNet 的基础上加入了注意力机制, 注意力机制在 CNN 中的应用十分广泛, 它能够放大我们需要的信号并且抑制不需要的信号, SmaAt-UNet 中采用了卷积注意力模块(CBAMs), 是一种结合了空间和通道的注意力机制模块, 具有轻量 and 通用的优点。同时采用 depthwise-separable 卷积取代传统的卷积, 实验表明, SmaAt-UNet 在牺牲少量指标的情况下, 能将参数量减少至原来的 1/4。<sup>[1]</sup>

采用基于注意力机制的 SmaAt-UNet 模型, 以 60 分钟的雷达回波图像作为输入, 生成未来 0-2 小时内、每隔五分钟一帧的降水预测。



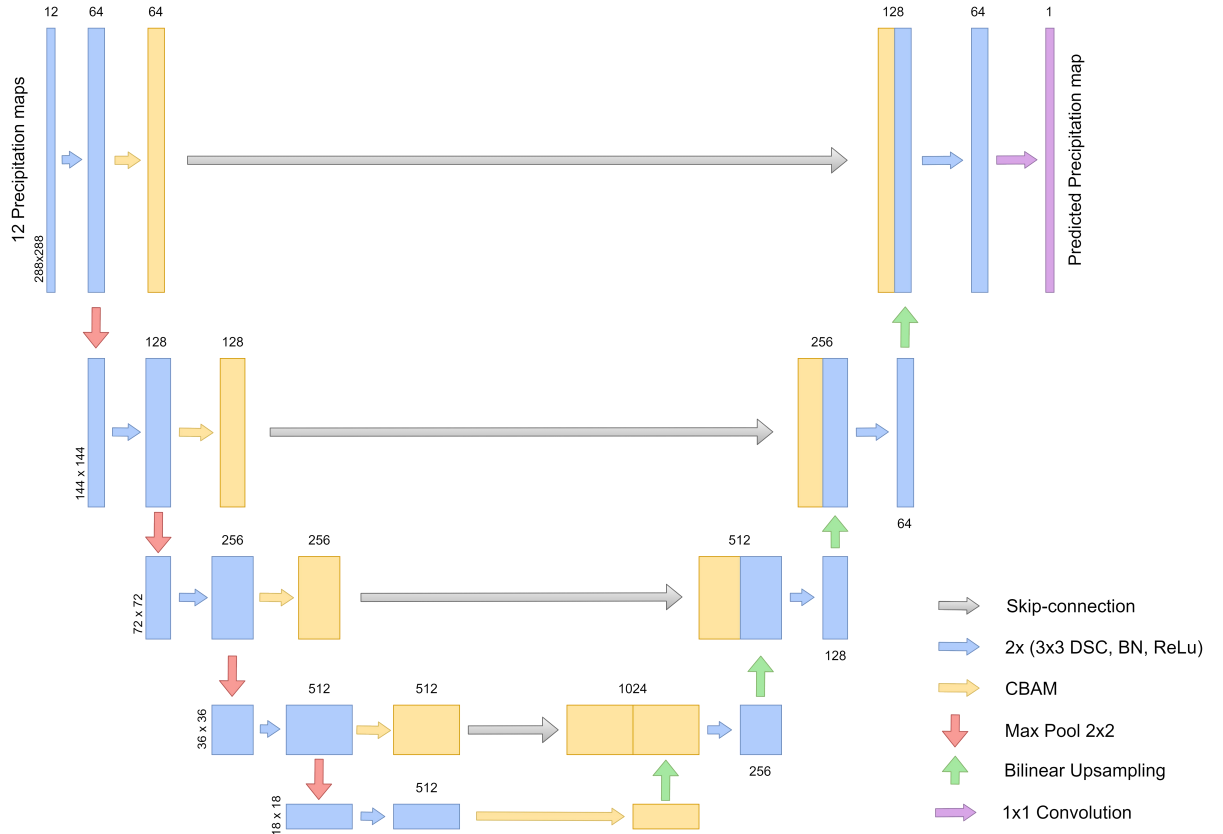


图 1 U-net 模型图<sup>[1]</sup>

## 1.2 predRNN 降水预测及模型优化

LSTM 是一种为解决长序列训练过程中的梯度消失和梯度爆炸问题的特殊 RNN，它可以有效进行长时间序列预测。本项目采用 PredRNN 模型为基准模型，并探索不同优化方案。

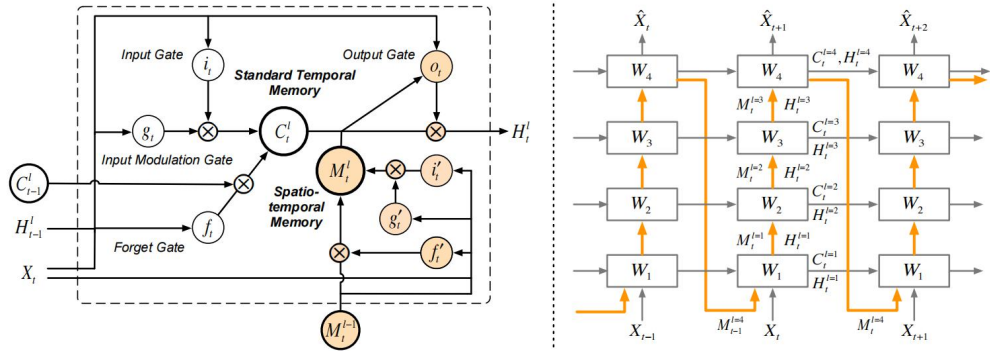


图 2 PredRNN 模型图<sup>[2]</sup>

一方面，将 LSTM 变体的 PredRNN 的结构由单向改为双向。双向 LSTM 是在 LSTM 网络的基础上，再增加一层 LSTM 网络，第二层 LSTM 的输入是第一层 LSTM 输入的反向序列，除此之外，它的传播方向也和第一层网络相反。反向的 LSTM 通过对输入序

列的逆向学习,可以保留部分未来的降水分布信息。通常情况下,两层 LSTM 一同训练,采用拼接,平均,求和等方式对两层 LSTM 输出进行合并,在此我们采取的是先平均再卷积的做法得到最终的输出。通过正反向 LSTM 的输出融合,模型能够学习云层移动的一些潜在规律。双向 PredRNN 结构如图 x 所示,需要说明,因每个方向模块内部的参数传递均与上述单向 LSTM 一致,故在图中不再标注参数传递具体内容。

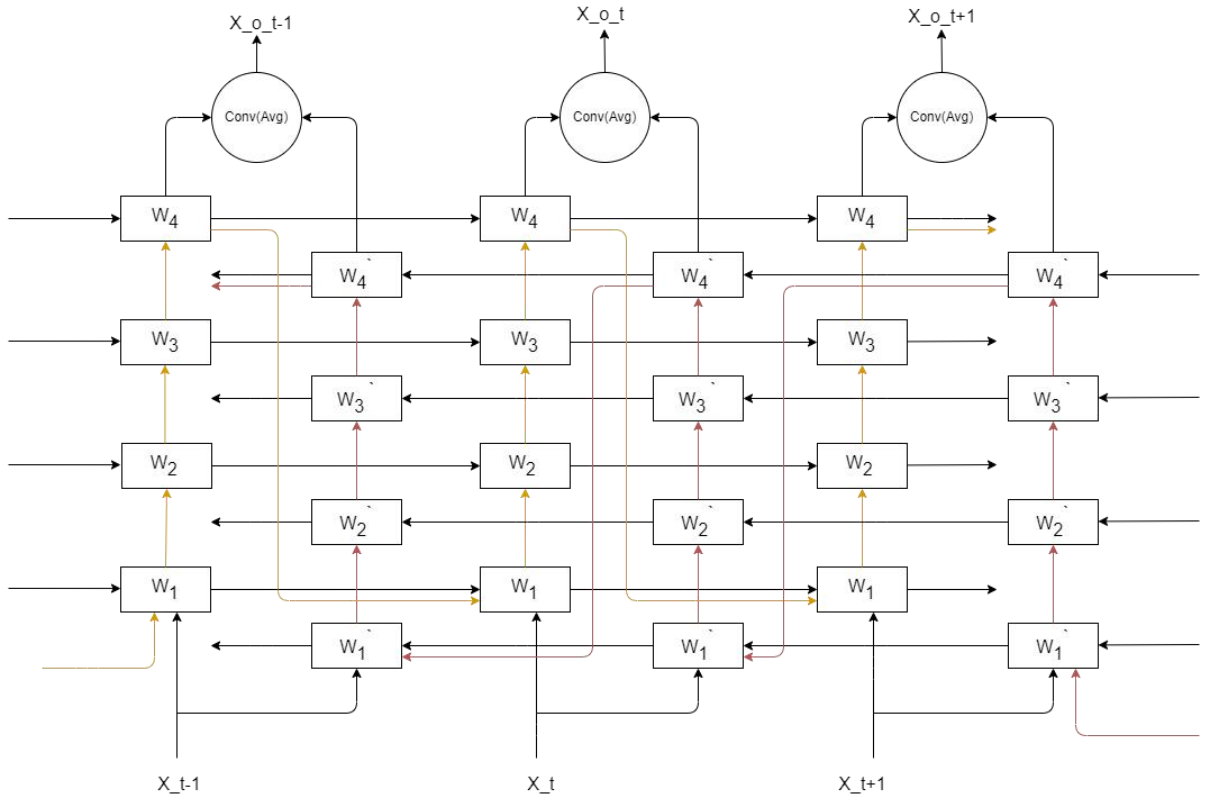


图 3 双向 PredRNN 模型图

另一方面,对生成的预测结果引入感知损失,在像素级误差的基础上增加感知误差,引导模型衡量预测结果在高层语义之间的相似性。

方法	Mse (↓)	Ssim (↑)	Psnr (↑)	Lpips (↓)	Precision (↑)	Recall (↑)	Accuracy (↑)	F1 (↑)	Csi (↑)	Far (↑)
U-Net	0.0160	-	-	-	0.6294	0.7964	0.7752	0.7031	0.5421	<b>0.3706</b>
PredRNN	0.01359	0.9858	13.59	<b>0.004159</b>	<b>0.6939</b>	<b>0.8403</b>	<b>0.8136</b>	<b>0.7586</b>	<b>0.6162</b>	0.3061
PredRNN +0.5*p_loss	0.0145	0.9850	13.56	0.004208	0.6723	0.8435	0.8001	0.7464	0.6000	0.3277
PredRNN +0.3*p_loss	<b>0.01357</b>	<b>0.9861</b>	<b>13.62</b>	0.004165	0.6864	0.8304	0.8079	0.7504	0.6059	0.3136

图 4 基础模型与考虑感知损失模型的性能指标

## 2. 模型集成

随着遥感技术的快速发展，遥感影像的分辨率、波段数等数据信息都获得了很大的提升，但是遥感图像检测任务仍然面临很大的挑战。近年来，深度学习算法在遥感图像分析中已经得到广泛普及。深度学习仿照人类视觉系统对外部信息的分级处理方式，通过组合底层特征形成更加抽象的高层特征。Long 等提出全卷积神经网络 FCN(Fully Convolution Networks),利用卷积层替代全连接层，可以接受任意尺寸的输入图像，实现对图像进行端到端的像素分类。由于全卷积网络没有考虑像素之间的关系，所得的结果不够精细，并且只对单个像素独立进行分类，没有考虑复杂的空间信息，导致预测结果比较粗糙。Ronneberger 等提出 UNet 网络，使用对称的解码器和编码器，并在编码器和解码器之间进行逐层跳跃连接，通过这种方法获得像素间的关系，实现像素的精确定位，但是由于其直接将编码器中的特征图和解码器中的特征图叠加，使得地物分类的边界粗糙。Oktay 等将注意力机制引入到 UNet 网络结构中，生成一个门控制信号，来控制不同位置特征的重要程度，虽然在一定程度上提高了变化检测精度，但是仍然存在漏检。

考虑到传统图像分析模型预测效果不稳定、泛化能力不强的现状，决定采用记忆能力较强的循环神经网络(RNN)和在图像分割领域表现良好且较为轻量的 UNet 网络作为基础并加以改进。采用 Stacking 集成策略对两者进行融合，提出了 predRNN-SmaAtUNet 集成深度学习预测模型。

### 2.1 Stacking 集成模型

集成学习的基本思想是通过某种策略融合多个学习器。与单一的学习器相比，集成学习的泛化性能更好。在 Stacking 集成框架中，需被组合的模型称为个体学习器，用来组合其他学习器的模型称为元学习器。

在 predRNN-SmaAtUNet 中，为了发挥 LSTM 的时序特性和 UNet 的图像理解优势，决定将 predRNN 和 SmaAtUNet 作为个体学习器，采用全连接神经网络（FCN）作为元学习器。Stacking 的优势在于能够把各个模型在提取特征较好的部分给抓取出来，同时舍弃它们各自表现不好的部分，这样就能有效地优化预测结果。集成模型示意图如图 5 所示




图 5 stacking 集成方式

### 3. 多源多模态数据融合

降雨是复杂的气象物理过程，预测降雨的数据分析工作中，我们需要处理不同来源、呈现出不同模态的数据。相比单一数据源，多源多模态数据通过相互补充修正，可以提供更准确地信息。此外，在信息的呈现上，多源多模态数据还增加了鲁棒性。气象预测对数据具有全面性的要求，故多源多模态数据的融合与集成是提高数据分析质量的重要基础。

多源数据就是取自多个端口的数据集合，而我们的平台中的多源数据来自于物理世界不同形态的广义传感器。多模态数据指不同形态的数据形式，或者同种形态不同的格式。总体而言，多模态数据是不能进行直接合并处理、却能产生相互联系的不同数据集<sup>[4]</sup>

数据融合技术将来自于多个传感器的数据和来自相关数据库的相关数据相结合，以得出比单个传感器更准确更具体的推论数据集。集成主要目标是集成多个信息源数据，多从逻辑和物理以及规范上进行集中，通过集成，具有不同特征的数据集将成为一个新的数据集，新的数据集应该表达与以前相同的含义，甚至挖掘出一些潜在的规则 and 知识。

[5]

最简单的数据融合方法是直接组合两个一维数据集中具有相同含义的一维数据集，或者从不同的数据集中抽取相同维度的数据进行直接连接。

我们还可以提取不同维度的数据进行融合分析，使用深度学习方法进行研究，如使用深度神经网络（DNN）从不同数据集提取的原始特征中学习的新表示形式，然后导入模型用于分类或者预测等数据分析工作中。

### 3.1 气象物理要素分类

为了利用物理约束，我们分别对降雨的气象过程和 NWP 格点数据集中的十七个物理要素做了详细调研。根据降雨量的成因，可以大致将 17 个物理要素分为对流类和凝结类，同属一类的物理要素可以在接下来的特征向量融合中作合并考虑，即合成高维特征向量。




图 6 降水的产生情况

原始特征	特征分类
V component of wind（高空水平风速度 Y 轴分量）	对流降雨
U component of wind（高空水平风速度 X 轴分量）	对流降雨
Potential vorticity（位势涡度）	对流降雨
Divergence（散度）	对流降雨
Geopotential Height（位势高度）	对流降雨
Convective available potential energy（对流有效位能）	对流降雨
Total cloud cover（总云量）	凝结降雨
Low cloud cover（低云量）	凝结降雨

表 1 气象物理要素分类

### 3.2 基于物理约束的特征向量融合

特征向量融合指直接串联各个特征，把各特征都均一融入到一个向量，从而直接用所有的向量数据生成一个更高维的向量。

数据集之间的特征可能并不独立，而是存在相关关系。针对这一问题，我们改进了

数据集特征融合的方法。我们期望在不考虑权重因子、阈值或启动参数的情况下，仅通过数据集特征之间的物理联系来构建了特殊的特征融合方法，并最后对此种方法进行结果检验。

原始特征	处理方式	处理原因
V component of wind (高空水平风速度 Y 轴分量)	合并	同质化特征合并处理, 共同表征 高空空气动力对对流降雨的影响
U component of wind (高空水平风速度 X 轴分量)	合并	同质化特征合并处理, 共同表征 高空空气动力对对流降雨的影响
Maximum temperature at 2 metres in the last 3 hours (过去 3 小时 2 米最高温 度)	合并	与温度特征耦合, 同时体现降雨 时序特性
Minimum temperature at 2 metres in the last 3 hours (过去 3 小时 2 米最低温 度)	合并	与温度特征耦合, 同时体现降雨 时序特性
Sea surface temperature (海平面温度)	合并	与温度特征耦合, 同时包含地理 特性的信息
Relative humidity (相对湿度)	保留	是降雨的直接成因
Specific humidity (比湿)	删除	由相对湿度和温度, 带入物理公 式, 可精确计算比湿
Temperature (高空温度)	保留	是降雨的直接成因, 且可用于代 替比湿特征

表 2 特征分类与处理方式

公式关系举例

相对湿度, 比湿, 高空温度

从比湿 (specific humidity) 计算相对湿度(RH)

$$E = 6.112 * e^{17.67 * t / (t + 243.5)}$$

$$q = 0.622e / (p - 0.378e)$$

其中：

t: 温度，单位为摄氏度 deg C

p: 水气压，单位为百帕，hpa 或者 mbar

q: 比湿，单位为 kg/kg

基于机器学习和深度学习的数据融合，是利用多个模式之间的特征层来实现融合，这也是目前多来源多模态数据融合的主要处理路径。

多模态深度学习融合和经典深度学习基本原理相同，只是用来学习和训练的数据集有所区别，从单一数据变为多源多模态数据集，或者是交叉使用不同模态的数据集。

### （三）产品展示

#### 1. web 前端

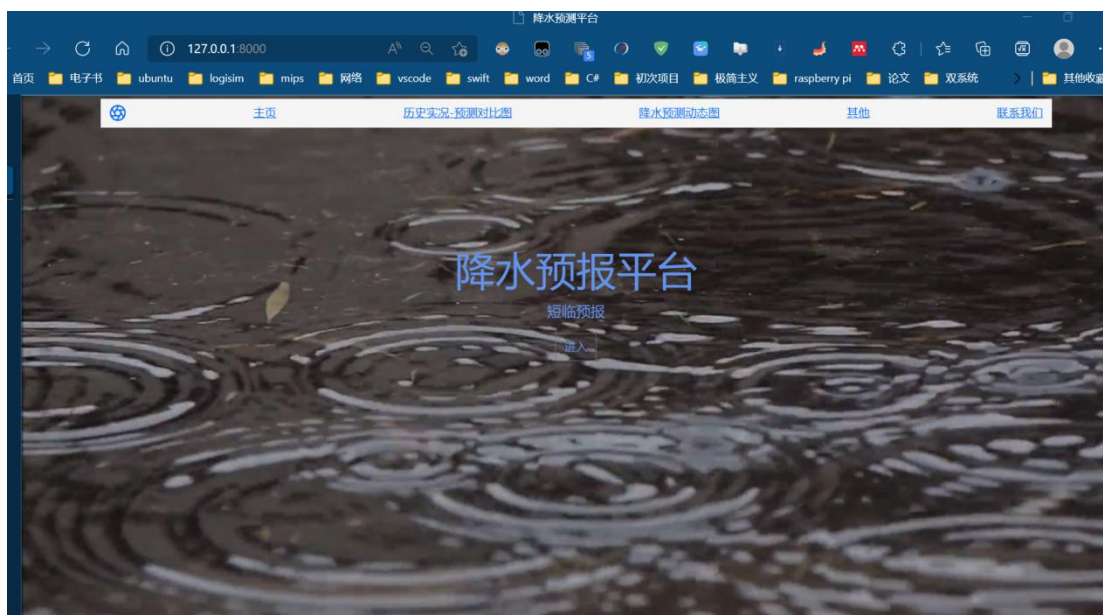


图 7 平台主页





图 8 历史实况-预测对比页面

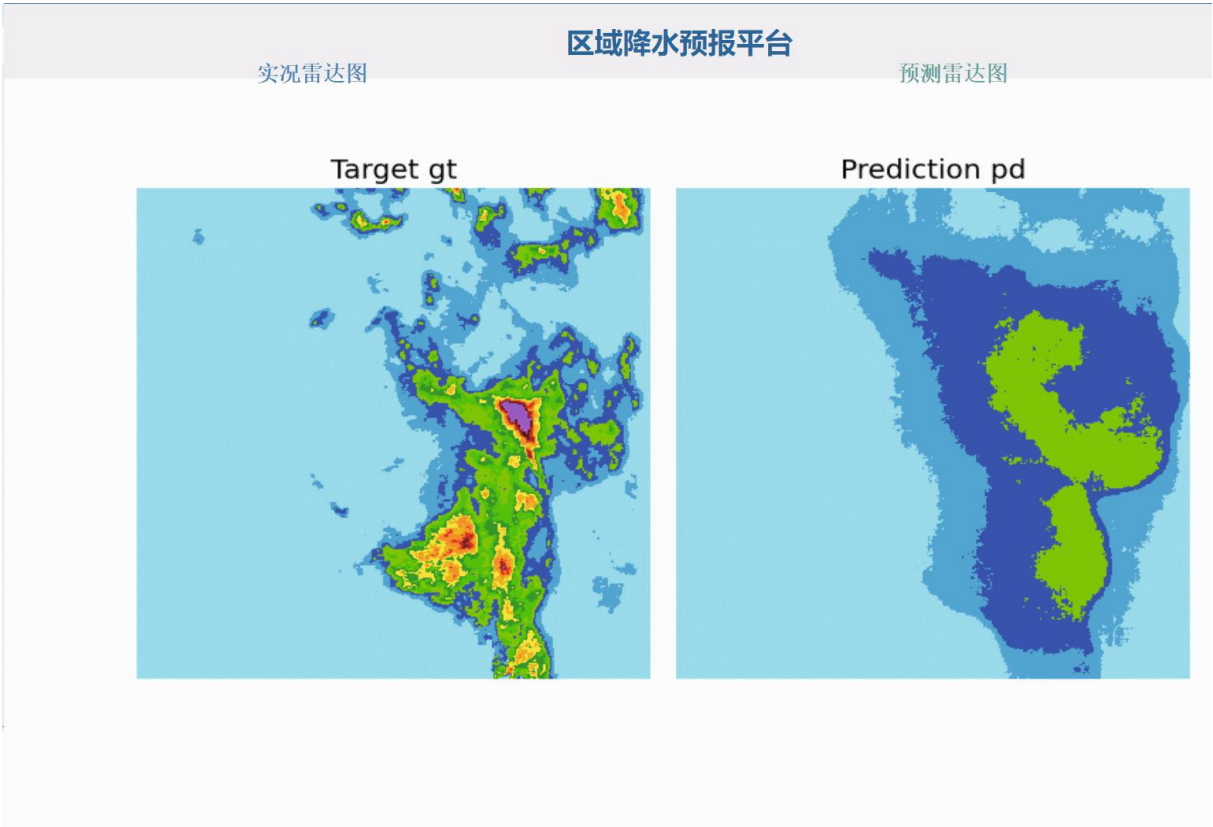


图 9 历史实况-预测对比图





图 10 未来降水预测首页

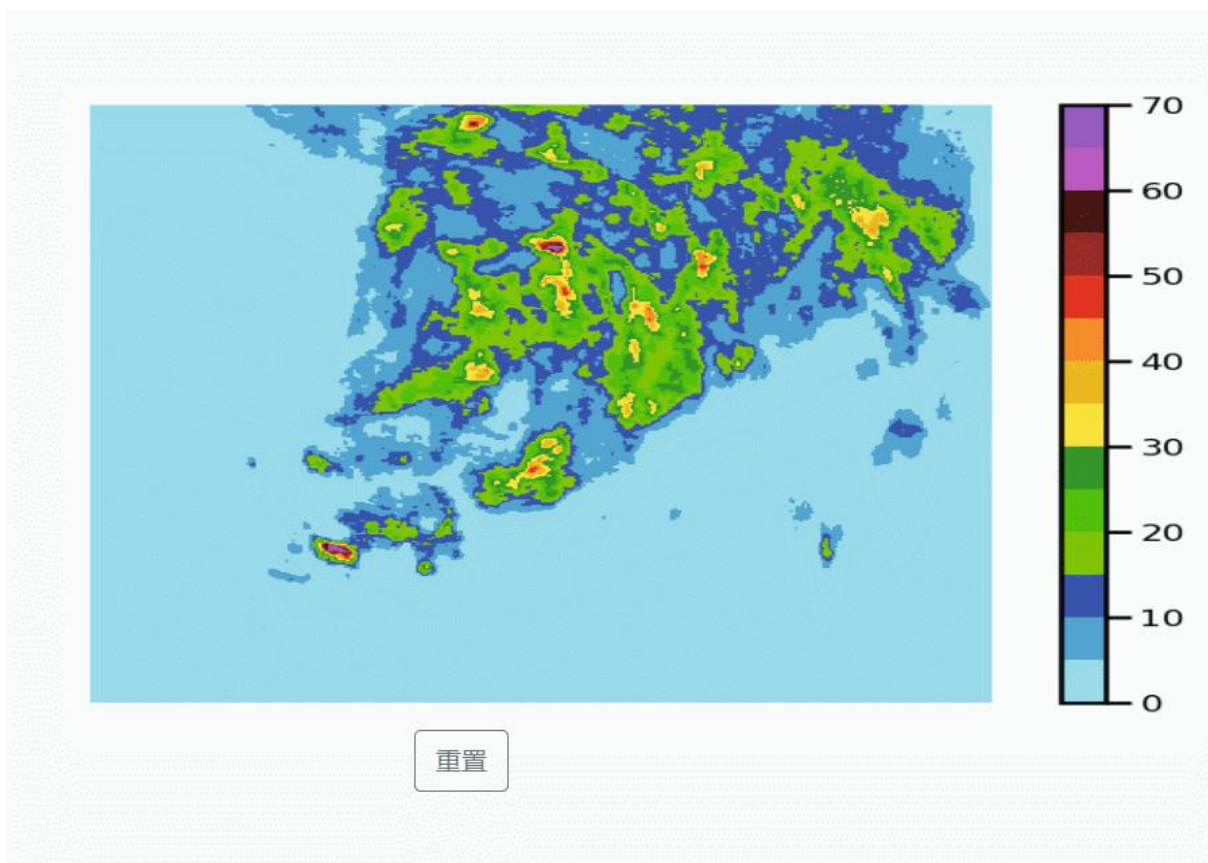


图 11 未来降水预测（页面中为动图）

#### 4. 算法后端

模型使用北航 HPC 服务进行训练，训练好的模型在算法中直接调用，整个算法打包成一个 python 包，在 django 应用中安装使用。前端界面点击预测查看按钮可以调用算

法进行预测。数据方面，目前国内对气象数据管理比较严格，我们所需的气象资料需要付费获取，因此我们暂且使用的是国外开源数据集，有条件时也可以支持实时数据。

### 三、商业模式

#### （一）市场分析

天气预报与人们的生活息息相关，能够获取及时、准确的天气预报能够为人们的穿衣、出行等提供很大的方便。随着短临预报的不断发展，如今对于一定时间间隔后的天气状况已经能够进行高准确的预报，然而对于短临天气的预报在准确率和实时性上还有待提高。

除了用于人们日常生活对天气的掌握，短临降雨预测对商业航空、主要从事户外工作的建筑行业、电力公司和地面运输服务公司等都有很高的应用价值。此外，对于极端天气的准确警告，如暴雨和洪水，能够保护生命和财产。所以，短临预报的实时性和准确性也变得尤为重要。

通过文献调研<sup>[6-9]</sup>，现有主流短临降雨预测算法的准确性如表 1 所示

Model	RMSE	EVS
Dual-channel MAR-CNN	7.90	0.77
Singel-channel CNN	10.29	0.63
GBDT	11.86	0.47
SVM	9.80	0.70

表 3 现有模型的一些指标

#### （二）产品定位

（1）功能定位：基于深度学习的短临降水预测比传统的预测方法具有预报时效更短，准确率更高等优点，可以为降雨预测提供回馈更及时的服务。我们能为这些提供更有效的预测，同时以网站作为开发平台，提供多区域短临降水预测服务，使得服务更为及时便利，且覆盖面广。同时平台提供历史预测结果和真实值的可视化对比来证明预报

精度。此外，平台根据输入数据及模型集成方式的不同，有不同的算法方案，对应有不同的可视化结果和评价指数，来提供更多样准确的服务。对应天气依赖性较强的产业，我们还难提供更准确的极端恶劣天气预测信息，以满足用户需求。

（2）目标用户定位：由于平台可以提供基于深度学习的较为准确的短临降水预测服务，并且支持不同区域的降水预测查询，所以产品的服务对象主要为受天气影响因素较大，需要短时降水信息的产业，如农业，商业，个体工商户等。

（3）产品风格定位：产品以深度学习算法作为服务支持，利用网页平台来直接提供服务。降水预测平台的功能特点等以及时简洁有效作为主要风格，目的在于更快捷有效的提供服务。整体风格符合短临降水预测平台设计的初衷，即更短时有有效。

（4）产品价值定位：本平台的主要价值在于可以提供可视化的 0-2 小时短时降水预测，并且采用多源多模态数据融合的方式，采用不同算法策略，以提供精准便捷的服务，来满足用户多样的使用需求。

### （三）推广计划

由于预测平台是基于网页搭建的，所以在推广上可以利用互联网的优势。初步的推广计划是现在对短时降水预测需求量大的相关产业进行推广。因为平台同时还提供历史降水与降水预测对比图，可以直观的展现出我们预测的有效性以及实时性，使得消费者能更直观的感受平台的使用价值。能融合多种数据，采取不同策略也是我们推广的重点。同时我们的平台是易于使用的，所以在农业等领域进行推广也具有一定的优势。

### （四）产品策略

（1）产品属性策略：该平台具有简洁高效实时等特点属性，且能针对多样数据以及不同的模型集成方法有不同的算法策略。提高预测准确度，优化可视化预测效果，是平台主要发展策略之一。

（2）产品包装策略：不同的模型集成方法，多源多模态的算法是核心技术支持，而产品的包装就是前端的网页开发。网页以实用为主，网页风格简洁明了，便于使用。且由于考虑到客户对短临降水预测有较大需求，我们利用多样化的可视化效果对预测算法的高效性提供包装，在满足客户需求的同时，让客户通过包装直观感受到预测的准确性。

(3) 产品服务策略：平台的服务策略主要是先积极引导客户尝试使用平台进行第一次预测，在这个过程中体现平台预测的准确性以及使用的便捷性，将分钟级更新的效果呈现给客户。同时再引导客户使用历史预测效果对比功能，以提高客户的使用体验以及对产品的信赖程度。在整个服务的过程中体现多样化的特点，如多算法方案、多数据融合处理方法，预测地区的多样化等等，以丰富客户的服务体验。

## 总结

本文从数据来源，数据处理，模型优化，模型集成等方面为深度学习在短临降水预报领域的应用提出了一种新的解决方案,多富的数据来源,基于大气物理知识的特征处理可以为模型训练提供高质量的特征，减少模型的过拟合程度；对 PredRNN 的模型优化以及和 U-net 的模型集成可以提供更优的训练模型。综合起来，预测精度和预测速度得到了提高。

由于时间和成本的原因，仍有一些想法没有实验验证，例如我们设想使用大气物理方程中简单的偏微分方程对神经网络损失函数进行约束，可以使收敛方向更符合现实物理规律，也使模型更具有可解释性，这是我们未来的工作方向。

## 参考文献

- [1] Kevin Trebing, Tomasz Stańczyk, Siamak Mehrkanon, SmaAt-UNet: Precipitation nowcasting using a small attention-UNet architecture, Pattern Recognition Letters, Volume 145, 2021, Pages 178–186,
- [2] Wang Y, Long M, Wang J, et al. PredRNN: Recurrent neural networks for predictive learning using spatiotemporal LSTMs. 2017.
- [3] 王婷, 刘云鹏, 董晨, 等. 短临降水预报方法及其应用研究综述[J]. 电子世界, 2019, (10): 11–13.
- [4] 余辉, 梁镇涛, 鄢宇晨. 多来源多模态数据融合与集成研究进展[J]. 情报理论与实践, 2020, 43(11): 169–178. DOI:10.16353/j.cnki.1000-7490.2020.11.027.
- [5] 祁友杰, 王琦. 多源数据融合算法综述[J]. 航天电子对抗, 2017, 33(06): 37–41. DOI:10.16328/j.htdz8511.2017.06.009.
- [6] C. Zhang, Z. Huang, S. Liu and J. Xiao, “Dual-Channel Multi-Task CNN for No-Reference Screen Content Image Quality Assessment,” in IEEE Transactions on Circuits and Systems for Video Technology
- [7] Yan, Qing & Ji, Fuxin & Miao, Kaichao & Wu, Qi & Xia, Yi & Li, Teng. (2020). Convolutional Residual-Attention: A Deep Learning Approach for Precipitation Nowcasting. Advances in Meteorology. 2020. 1–12.
- [8] Prudden, Rachel & Adams, Samantha & Kangin, Dmitry & Robinson, Niall & Ravuri, Suman & Mohamed, Shakir & Arribas, Alberto. (2020). A review of radar-based nowcasting of precipitation and applicable machine learning techniques.
- [9] Bouget, V.; Béréziat, D.; Brajard, J.; Charantonis, A.; Filoche, A. Fusion of Rain Radar Images and Wind Forecasts in a Deep Learning Model Applied to Rain Nowcasting. Remote Sens. 2021, 13, 246.

